Adéquation algorithme architecture

Accélération de méthodes d'inversion de données en grande dimension

Nicolas GAC

PU Université Paris-Saclay

séminaire maison de la simulation - 24 oct. 2023







Adéquation Algorithme Architecture

Meilleure **combinaison d'architectures et d'algorithmes** sous **contraintes**

- temps de traitement
- précision de calcul
- consommation énergétique
- coût du système de calcul
- temps de développement
- éco-responsabilité

Adéquation Algorithme Architecture

Meilleure **combinaison d'architectures et d'algorithmes** sous **contraintes**

- temps de traitement
- précision de calcul
- consommation énergétique
- coût du système de calcul
- temps de développement
- éco-responsabilité

A^3 interdisciplinaire

- Algorithmes pour **problèmes inverses**

  radioastronomie, *IA embarquée*, *tomographie*, *radar*, *planétologie*, *localisation de sources acoustiques*, *flot optique dense*

Adéquation Algorithme Architecture

Meilleure **combinaison d'architectures et d'algorithmes** sous **contraintes**

- temps de traitement
- précision de calcul
- consommation énergétique
- coût du système de calcul
- temps de développement
- éco-responsabilité

A^3 interdisciplinaire

- Algorithmes pour **problèmes inverses**
  radioastronomie, IA embarquée, tomographie, radar, planétologie, localisation de sources acoustiques, flot optique dense
- Architectures de **calcul intensif**
  GPU, multiGPU, SoC GPU, FPGA

Adéquation Algorithme Architecture

Meilleure **combinaison d'architectures et d'algorithmes** sous **contraintes**

- temps de traitement
- précision de calcul
- consommation énergétique
- coût du système de calcul
- temps de développement
- éco-responsabilité

A^3 interdisciplinaire

- Algorithmes pour **problèmes inverses**
  radioastronomie, IA embarquée, tomographie, radar, planétologie, localisation de sources acoustiques, flot optique dense
- Architectures de **calcul intensif**
  GPU, multiGPU, SoC GPU, FPGA

$\Longrightarrow$ *Comment se rapprocher des performances maximales ?*

Adéquation Algorithme Architecture

Meilleure **combinaison d'architectures et d'algorithmes** sous **contraintes**

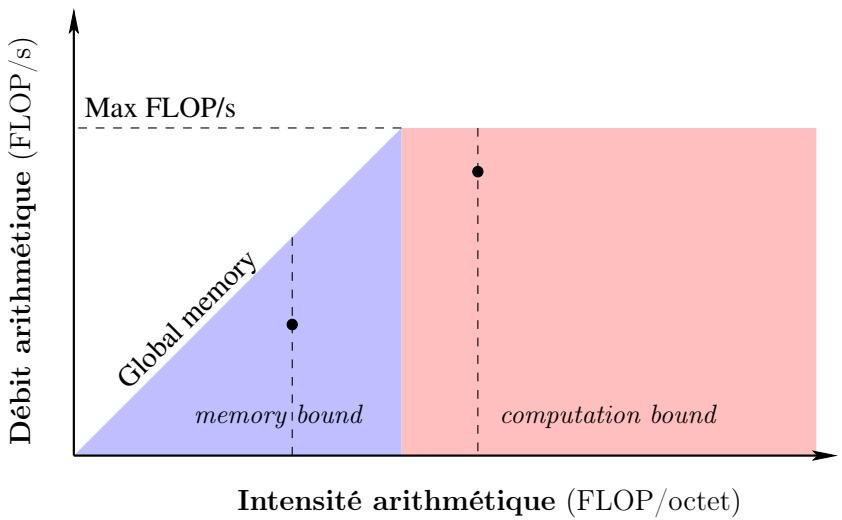
- temps de traitement
- précision de calcul
- consommation énergétique
- coût du système de calcul
- temps de développement
- éco-responsabilité

A^3 interdisciplinaire

- Algorithmes pour **problèmes inverses**
  radioastronomie, IA embarquée, tomographie, radar, planétologie, localisation de sources acoustiques, flot optique dense
- Architectures de **calcul intensif**
  GPU, multiGPU, SoC GPU, FPGA

$\Longrightarrow$ *Comment se rapprocher des performances maximales ?*

The Berkeley **roofline model**



[Williams 2009]

Adéquation Algorithme Architecture

Meilleure **combinaison d'architectures et d'algorithmes** sous **contraintes**

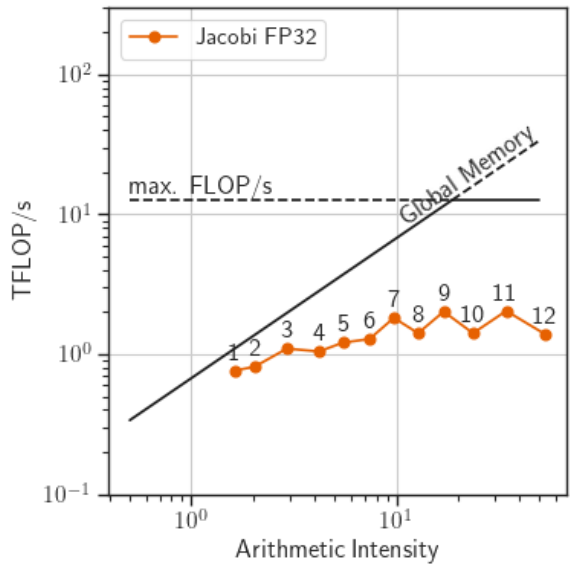
- temps de traitement
- précision de calcul
- consommation énergétique
- coût du système de calcul
- temps de développement
- éco-responsabilité

A^3 interdisciplinaire

- Algorithmes pour **problèmes inverses**
  radioastronomie, IA embarquée, tomographie, radar, planétologie, localisation de sources acoustiques, flot optique dense
- Architectures de **calcul intensif**
  GPU, multiGPU, SoC GPU, FPGA

$\Longrightarrow$ *Comment se rapprocher des performances maximales ?*

The Berkeley **roofline model**



[JRTIP 2022b]

Adéquation Algorithme Architecture

Meilleure **combinaison d'architectures et d'algorithmes** sous **contraintes**

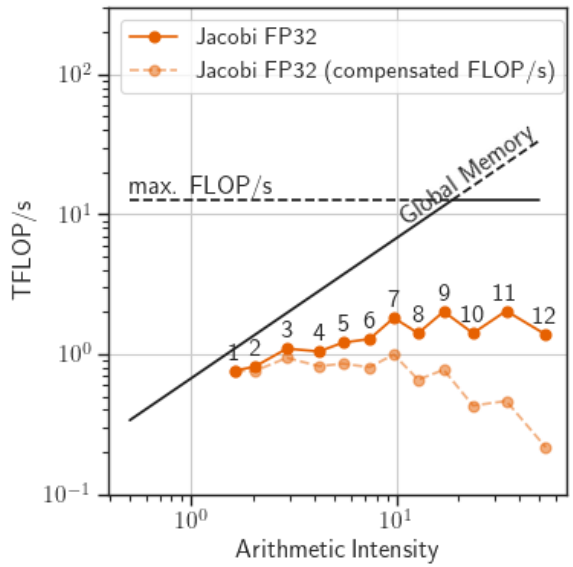
- temps de traitement
- précision de calcul
- consommation énergétique
- coût du système de calcul
- temps de développement
- éco-responsabilité

A^3 interdisciplinaire

- Algorithmes pour **problèmes inverses**
  radioastronomie, IA embarquée, tomographie, radar, planétologie, localisation de sources acoustiques, flot optique dense
- Architectures de **calcul intensif**
  GPU, multiGPU, SoC GPU, FPGA

$\Longrightarrow$ *Comment se rapprocher des performances maximales ?*

The Berkeley **roofline model**



[JRTIP 2022b]

Adéquation Algorithme Architecture

Meilleure **combinaison d'architectures et d'algorithmes** sous **contraintes**

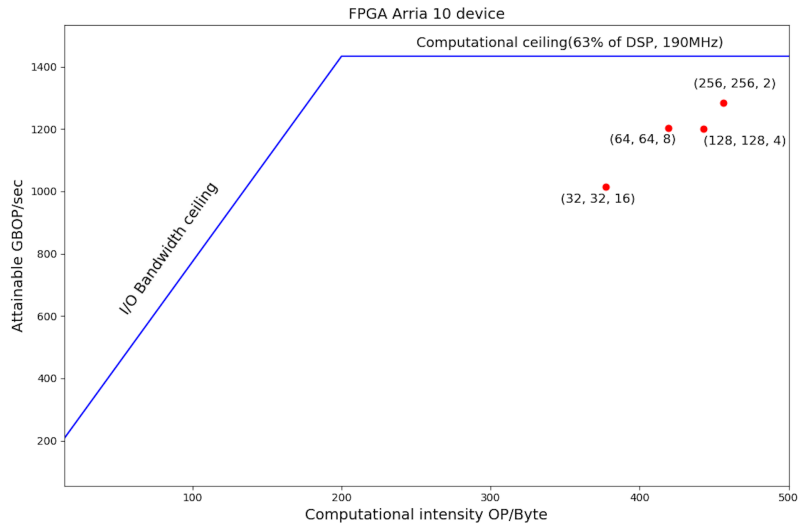
- temps de traitement
- précision de calcul
- consommation énergétique
- coût du système de calcul
- temps de développement
- éco-responsabilité

A^3 interdisciplinaire

- Algorithmes pour **problèmes inverses**
  radioastronomie, IA embarquée, tomographie, radar, planétologie, localisation de sources acoustiques, flot optique dense
- Architectures de **calcul intensif**
  GPU, multiGPU, SoC GPU, FPGA

$\Longrightarrow$ *Comment se rapprocher des performances maximales ?*

The Berkeley **roofline model**



[IEEE TBioCAS 2023]

Adéquation Algorithme Architecture

Meilleure **combinaison d'architectures et d'algorithmes** sous **contraintes**

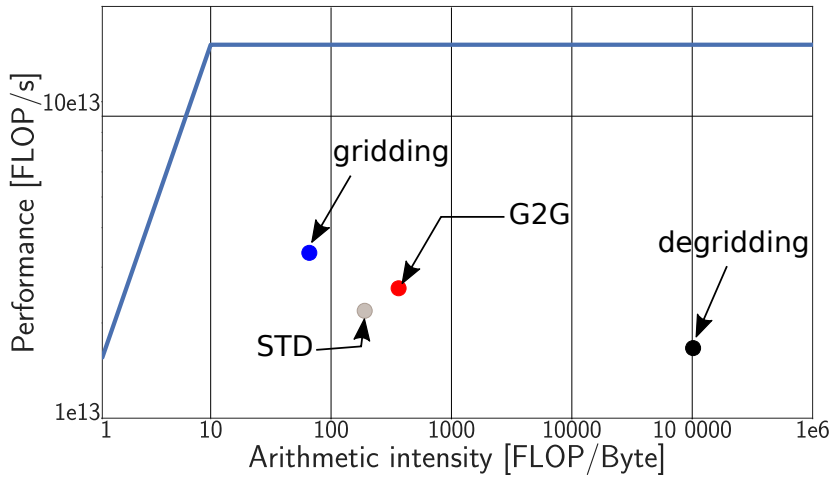
- temps de traitement
- précision de calcul
- consommation énergétique
- coût du système de calcul
- temps de développement
- éco-responsabilité

A^3 interdisciplinaire

- Algorithmes pour **problèmes inverses**
  radioastronomie, IA embarquée, tomographie, radar, planétologie, localisation de sources acoustiques, flot optique dense
- Architectures de **calcul intensif**
  GPU, multiGPU, SoC GPU, FPGA

$\Longrightarrow$ *Comment se rapprocher des performances maximales ?*

The Berkeley **roofline model**



Algorithme G2G [IEEE ICIP 2022]

Radioastronomie

SKA

- **Radiotélescope géant**
- Défi calculatoire
  - $\Longrightarrow$ Traitement temps réel
  - $\Longrightarrow$ Ressources énergétiques limitées
- Porteur ANR Dark-era (2021-25)

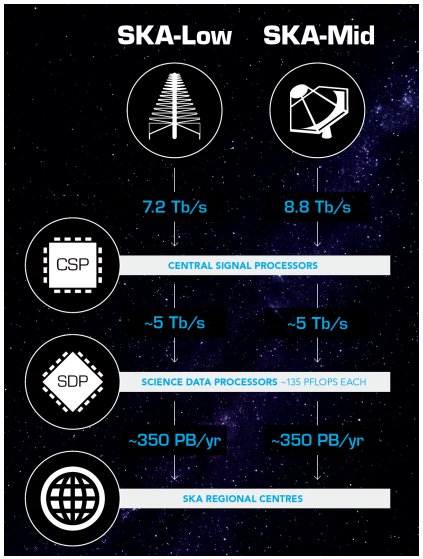


Square Kilometer Array (SKA)

Radioastronomie

SKA

- Radiotélescope géant
- **Défi calculatoire**
  - $\Longrightarrow$ Traitement **temps réel**
  - $\Longrightarrow$ Ressources **énergétiques** limitées
- Porteur ANR Dark-era (2021-25)



Pipeline SKA

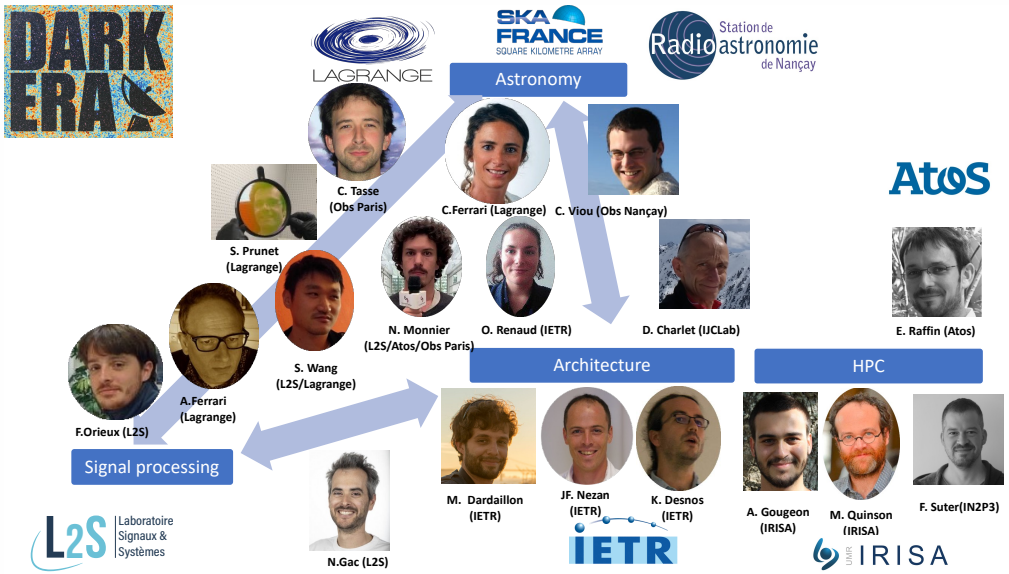
Radioastronomie

SKA

- Radiotélescope géant
- Défi calculatoire
  - ⟹ Traitement **temps réel**
  - ⟹ Ressources **énergétiques** limitées
- **Porteur ANR Dark-era (2021-25)**

  L2S, IETR, OCA, IRISA, OP

[CNRS Interdisciplinarité 2023]



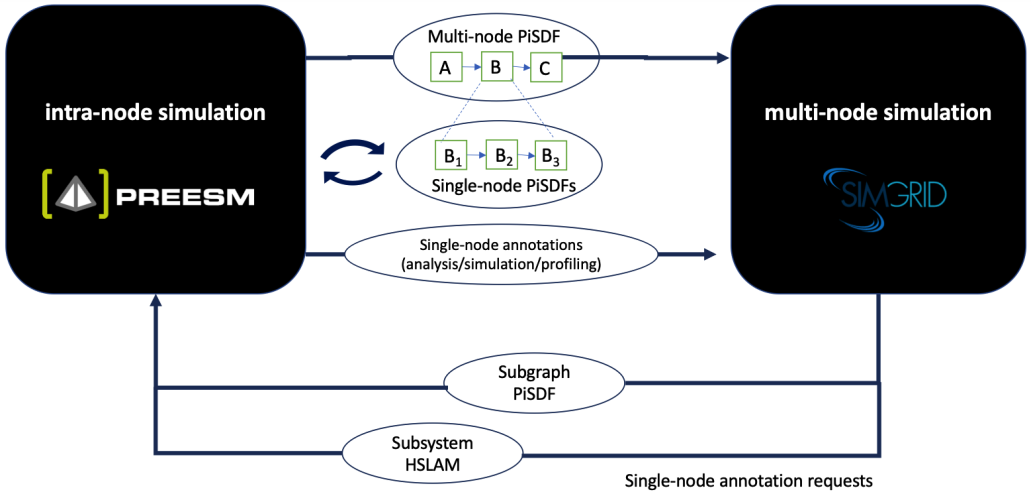
Radioastronomie

SKA

- Radiotélescope géant
- Défi calculatoire
  - $\Longrightarrow$ Traitement **temps réel**
  - $\Longrightarrow$ Ressources **énergétiques** limitées
- **Porteur ANR Dark-era (2021-25)**

  L2S, IETR, OCA, IRISA, OP

[CNRS Interdisciplinarité 2023]



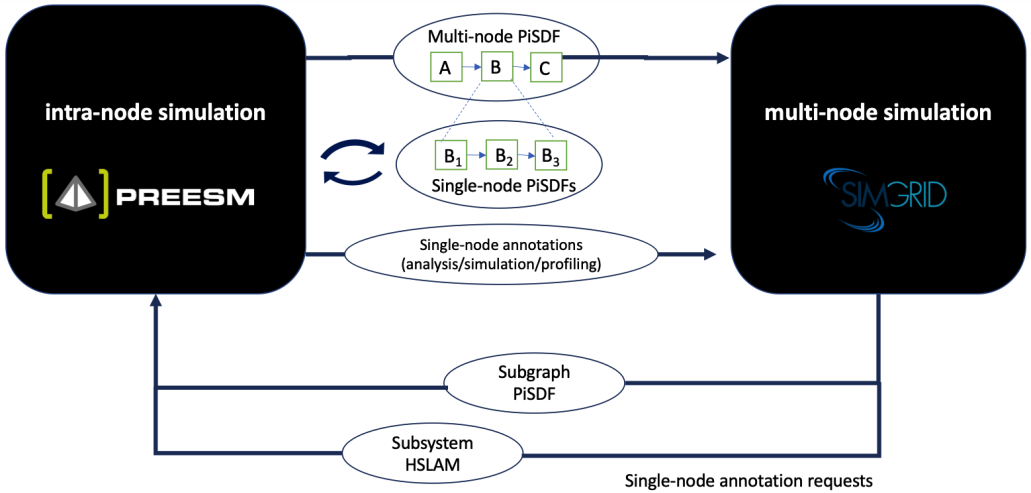
Simulateur SimSDP

Radioastronomie

SKA

- Radiotélescope géant
- Défi calculatoire
  - $\Longrightarrow$ Traitement **temps réel**
  - $\Longrightarrow$ Ressources **énergétiques** limitées
- Porteur ANR Dark-era (2021-25)
  L2S, IETR, OCA, IRISA, OP

[CNRS Interdisciplinarité 2023]



Simulateur SimSDP

Axe de recherche au SATIE

$\Longrightarrow$ Équipe MOSS

Pascal Larzabal, Lucien Bacharach et Isabelle Vin

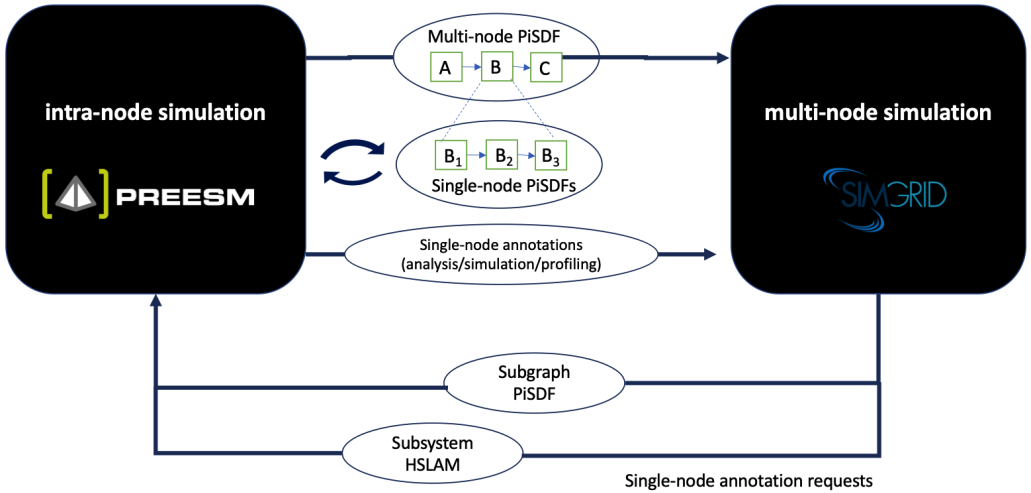
Radioastronomie

SKA

- Radiotélescope géant
- Défi calculatoire
  - $\Longrightarrow$ Traitement **temps réel**
  - $\Longrightarrow$ Ressources **énergétiques** limitées
- Porteur ANR Dark-era (2021-25)

  L2S, IETR, OCA, IRISA, OP

[CNRS Interdisciplinarité 2023]



Simulateur SimSDP

Axe de recherche au SATIE

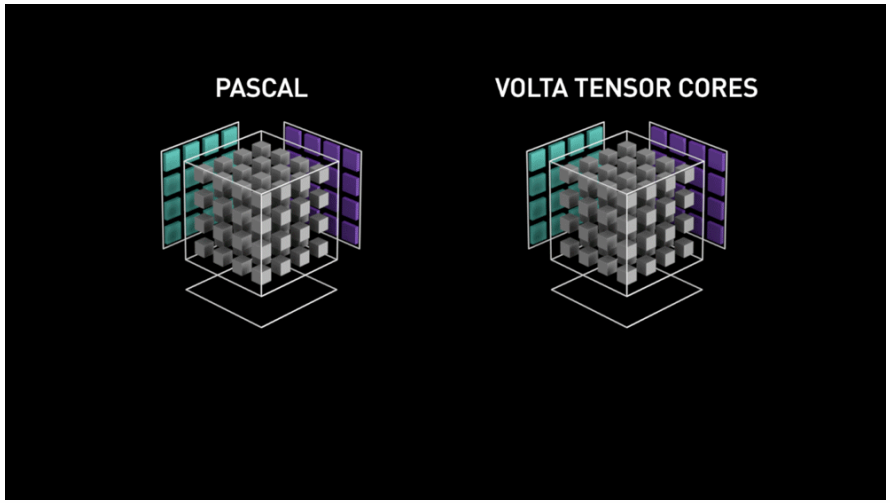
$\Longrightarrow$ Équipe MOSS *Pascal Larzabal, Lucien Bacharach et Isabelle Vin*

- SKA-France : UPSay membre du copil
- ECLAT : Laboratoire commun CNRS/INRIA/Atos Bull

IA embarquée

Deep Neural Network (DNN) sur GPU

- System on Chip (SoC) NVIDIA
  - CUDA cores
  - Tensor cores
  - Deep Learning Accelerator
- Collaboration avec Thales TRT



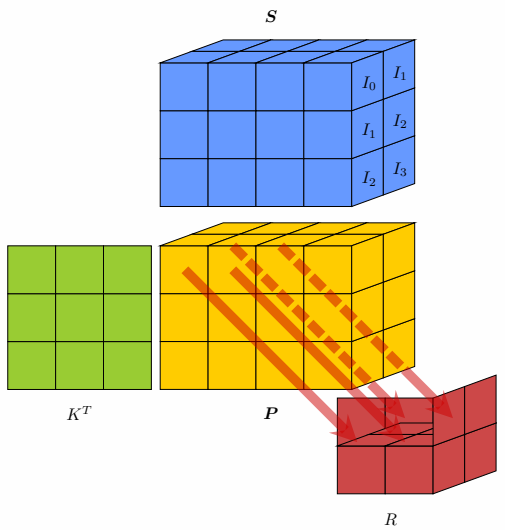
NVIDIA tensor cores

IA embarquée

Deep Neural Network (DNN) sur GPU

- System on Chip (SoC) NVIDIA
  - CUDA cores
  - Tensor cores
  - Deep Learning Accelerator
- Collaboration avec Thales TRT

2018-21 Convolution 2D sur tensor cores



Algorithme im2tensor [JRTIP 2022a]

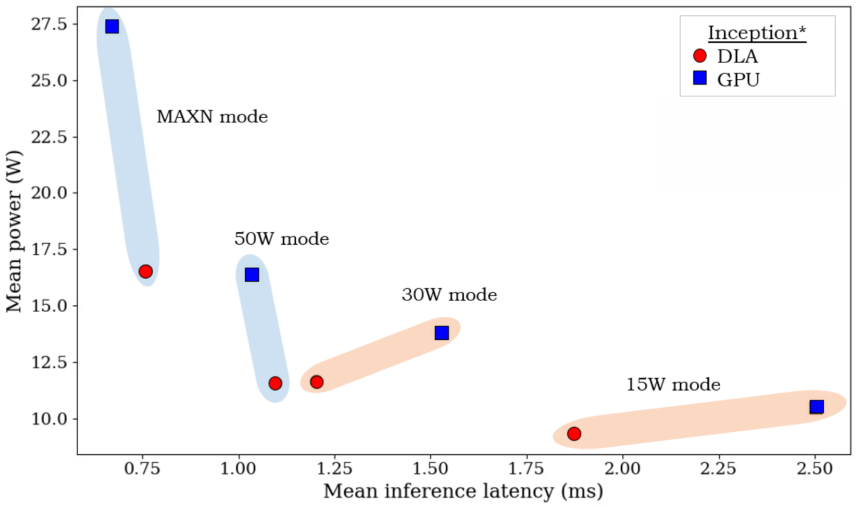
IA embarquée

Deep Neural Network (DNN) sur GPU

- System on Chip (SoC) NVIDIA
  - CUDA cores
  - Tensor cores
  - Deep Learning Accelerator
- Collaboration avec Thales TRT

2018-21 Convolution 2D sur tensor cores

2022-25 Neural Architecture Search



DNN inception sur Jetson Orin

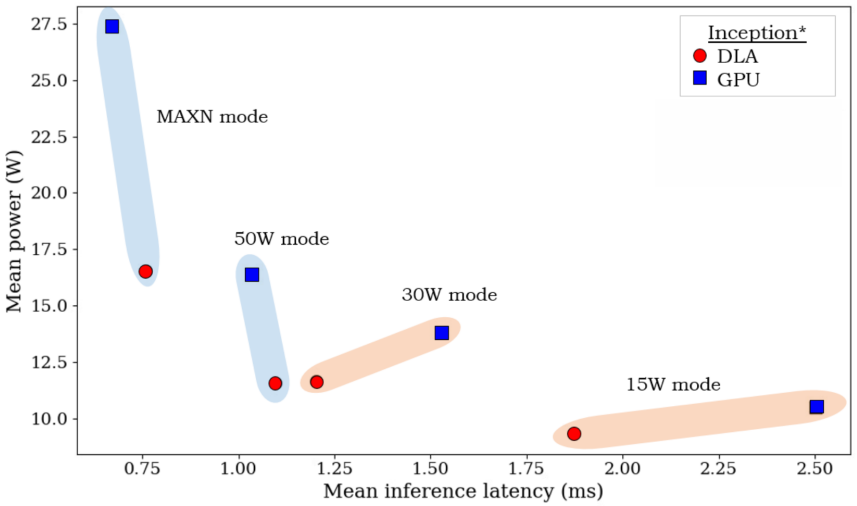
IA embarquée

Deep Neural Network (DNN) sur GPU

- System on Chip (SoC) NVIDIA
  - CUDA cores
  - Tensor cores
  - Deep Learning Accelerator
- Collaboration avec Thales TRT

2018-21 Convolution 2D sur tensor cores

2022-25 Neural Architecture Search



DNN inception sur Jetson Orin

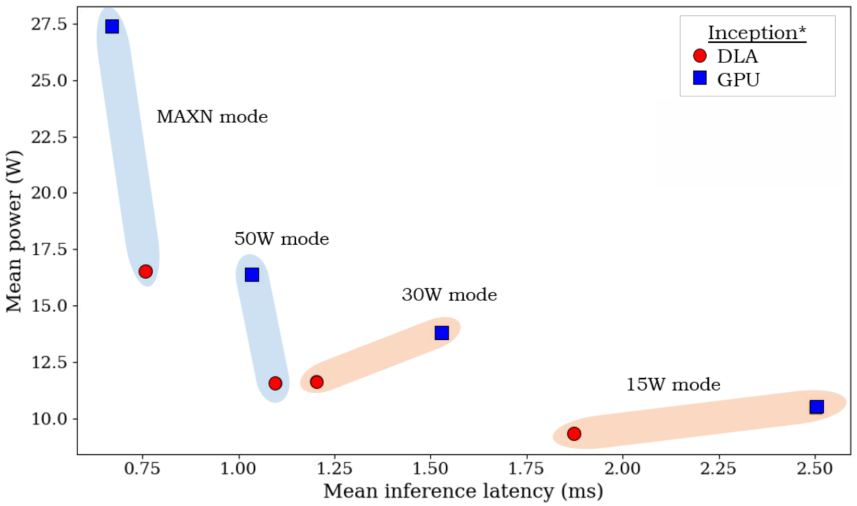
IA embarquée

Deep Neural Network (DNN) sur GPU

- System on Chip (SoC) NVIDIA
  - CUDA cores
  - Tensor cores
  - Deep Learning Accelerator
- Collaboration avec Thales TRT

2018-21 Convolution 2D sur tensor cores

2022-25 Neural Architecture Search



DNN inception sur Jetson Orin

Reconstruction tomographique

Problème inverse à large échelle

- Méthodes bayésiennes au sein du GPI

  [IEEE TCI 2019, Entropy 2018, FI 2017a, FI 2017b]

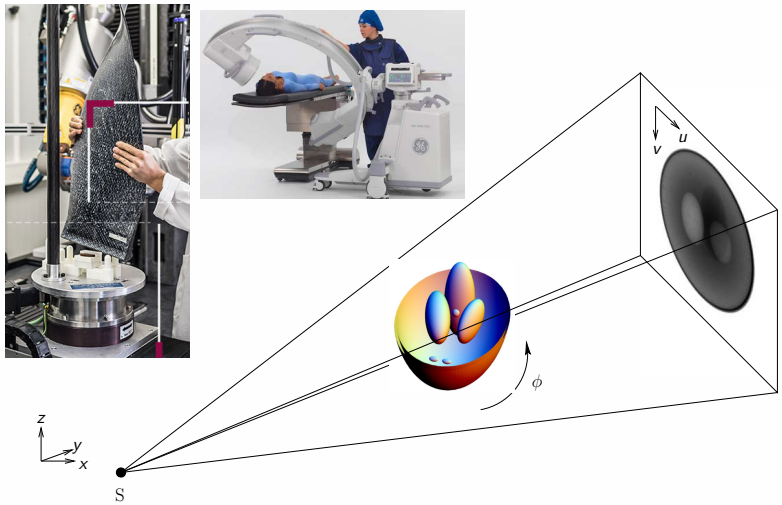
- Accélération GPU/multiGPU/FPGA

  [IEEE TBioCAS 2023, JSPS 2018]

- Logiciels et brevet

  [TomoGPI 2022, TomoBayes 2019]

  [Brevet SAFRAN 2019]

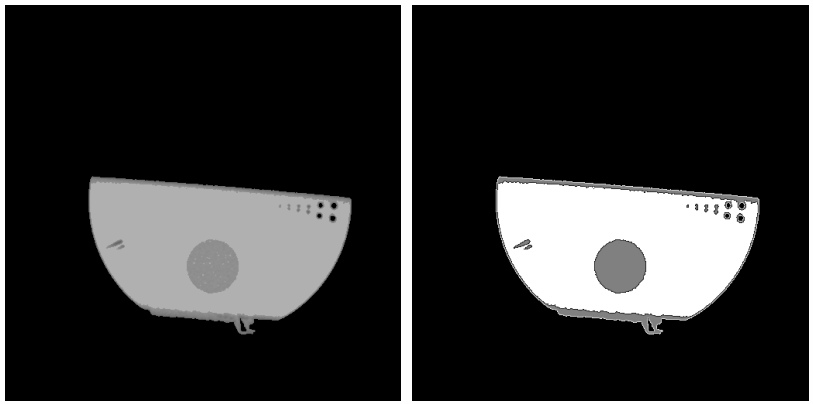


Tomographie à rayons X

Reconstruction tomographique

Problème inverse à large échelle

- **Méthodes bayésiennes au sein du GPI**
  [IEEE TCI 2019, Entropy 2018, FI 2017a, FI 2017b]
- Accélération GPU/multiGPU/FPGA
  [IEEE TBioCAS 2023, JSPS 2018]
- Logiciels et brevet
  [TomoGPI 2022, TomoBayes 2019]
  [Brevet SAFRAN 2019]



Reconstruction avec segmentation (SAFRAN)

Reconstruction tomographique

Problème inverse à large échelle

- Méthodes bayésiennes au sein du GPI

  [IEEE TCI 2019, Entropy 2018, FI 2017a, FI 2017b]

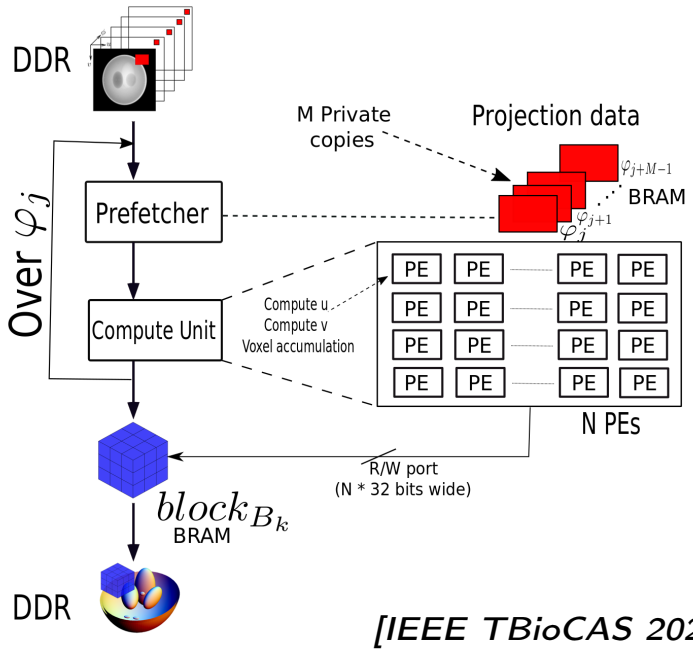
- **Accélération GPU/multiGPU/FPGA**

  [IEEE TBioCAS 2023, JSPS 2018]

- Logiciels et brevet

  [TomoGPI 2022, TomoBayes 2019]

  [Brevet SAFRAN 2019]



[IEEE TBioCAS 2023]

Reconstruction tomographique

Problème inverse à large échelle

- Méthodes bayésiennes au sein du GPI

  [IEEE TCI 2019, Entropy 2018, FI 2017a, FI 2017b]

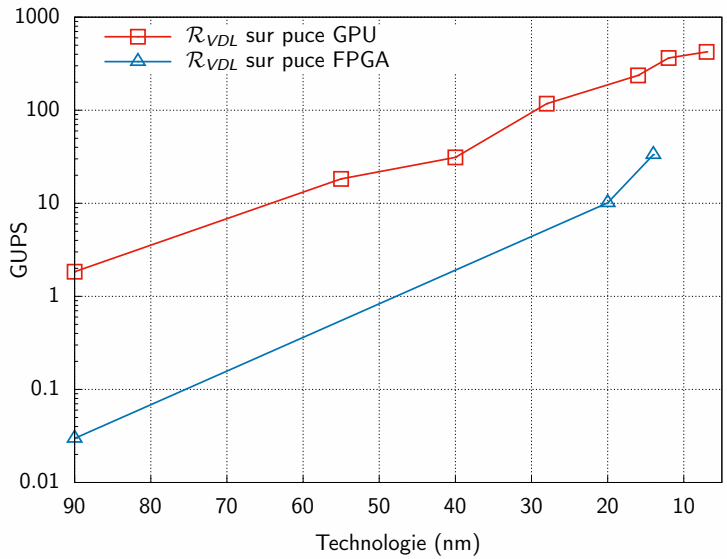
- **Accélération GPU/multiGPU/FPGA**

  [IEEE TBioCAS 2023, JSPS 2018]

- Logiciels et brevet

  [TomoGPI 2022, TomoBayes 2019]

  [Brevet SAFRAN 2019]



Rétroprojection GPU vs FPGA

Reconstruction tomographique

Problème inverse à large échelle

- Méthodes bayésiennes au sein du GPI

  [IEEE TCI 2019, Entropy 2018, FI 2017a, FI 2017b]

- Accélération GPU/multiGPU/FPGA

  [IEEE TBioCAS 2023, JSPS 2018]

- **Logiciels et brevet**

  [TomoGPI 2022, TomoBayes 2019]

  [Brevet SAFRAN 2019]



Démonstrateur tomoGPI

Reconstruction tomographique

Problème inverse à large échelle

- Méthodes bayésiennes au sein du GPI
  [IEEE TCI 2019, Entropy 2018, FI 2017a, FI 2017b]
- Accélération GPU/multiGPU/FPGA
  [IEEE TBioCAS 2023, JSPS 2018]
- Logiciels et brevet
  [TomoGPI 2022, TomoBayes 2019]
  [Brevet SAFRAN 2019]



Démonstrateur tomoGPI

Reconstruction tomographique

Problème inverse à large échelle

- Méthodes bayésiennes au sein du GPI
  [IEEE TCI 2019, Entropy 2018, FI 2017a, FI 2017b]
- Accélération GPU/multiGPU/FPGA
  [IEEE TBioCAS 2023, JSPS 2018]
- Logiciels et brevet
  [TomoGPI 2022, TomoBayes 2019]
  [Brevet SAFRAN 2019]



Démonstrateur tomoGPI

Articles de journaux (1/2)

[IEEE TBioCAS 2023] D. Diakite, N. Gac, **X-ray tomography reconstruction accelerated on FPGA through High-Level Synthesis tools**, *IEEE Transactions on Biomedical Circuits and Systems, 2023*

[CNRS interdisciplinarité 2023] N. Gac et al., **Prototypage rapide d'un supercalculateur dédié à la radioastronomie**, *Ouvrage du CNRS sur l'interdisciplinarité), CNRS-Éditions, 2023*

[JRTIP 2022a] M. Seznec, N. Gac, F. Orieux, A. Sashala Naik, **Computing Large 2D Convolutions on GPU Efficiently with the im2tensor Algorithm**, *Journal of Real-Time Image Processing, Springer Verlag, 2022*

[JRTIP 2022b] M. Seznec, N. Gac, F. Orieux, A. Sashala Naik, **Real-Time Optical Flow Processing on Embedded GPU : an Hardware-Aware Algorithm to Implementation Strategy**, *Journal of Real-Time Image Processing, Springer Verlag, 2021*

[A&A 2019] A. Marchal, M.A. Miville-Deschênes, F. Orieux, N. Gac, C. Soussen, M.J. Lesot, A. Revault d'Allonnes, Q. Salomé, **ROHSA : Regularized Optimization for Hyper-Spectral Analysis**, *Astronomy and Astrophysics - AA, 2019*

[IEEE TCI 2019] C. Chapdelaine, A. Mohammad-Djafari, N. Gac, E. Parra, **Error-Splitting Forward Model for Iterative Reconstruction in X-ray Computed Tomography and application with Gauss-Markov-Potts prior**, *IEEE Transactions on Computational Imaging, 2019*

[JSPS 2018] M. Martelli, N. Gac, A. Merigot, C. Enderli, **3D Tomography back-projection parallelization on Intel FPGAs using OpenCL**, *Journal of Signal Processing Systems, Springer, 2018*

[Entropy 2018] L. Wang, A. Djafari, N. Gac, M. Dumitru, **3D X-ray CT with a Hierarchical Prior model for Sparsity in Haar Transform domain**, *Entropy, Special Issue Probabilistic Methods for Inverse Problems, MDPI, 2018*

[FI 2017a] L. Wang, A. Djafari, N. Gac, **X-ray Computed Tomography using a sparsity enforcing prior model based on Haar transformation in a Bayesian framework**, *Special Issue of Fundamenta Informaticae, IOS Press, 2017*

[FI 2017b] C. Chapdelaine, A. Djafari, N. Gac, E. Parra, **A 3D Bayesian CT Reconstruction Algorithm with Gauss-Markov-Potts Prior Model**, *Special Issue of Fundamenta Informaticae, IOS Press, 2017*

[Appl. Acoust. 2014] N. Chu, J. Picheral, A. Djafari, N. Gac, **A robust super-resolution approach with sparsity constraint in acoustic imaging**, *Applied Acoustics, Elsevier, 2014, 76, pp.197-208.*

[P&SS 2014] F. Schmidt, I. Shatalina, M. Kowalski, N. Gac, B. Saggin, et al., **Toward a numerical deshaker for PFS**, *Planetary and Space Science, Elsevier, 2014, 91, pp.45 - 51.*

Articles de journaux (2/2)

[TS 2013] T. Boulay, N. Gac, A. Mohammad-Djafari, J. Lagoutte, **Algorithmes de reconnaissance NCTR et parallélisation sur GPU**, *Traitement du Signal, Lavoisier, 2013, 6, pp.309-342.*

[Elsevier NIMPS 2012] M.L. Gallin-Martel., Y. Grondin, N. Gac et al, **Experimental results and first 22Na source image reconstruction ... for small animal imaging**, *Nuclear Instruments and Methods in Physics Research, Elsevier, 2012*

[EURASIP JES 2009] N. Gac, S.Mancini, M. Desvignes et D. Houzet, **High Speed 3D Tomography on CPU, GPU and FPGA**, *EURASIP Journal on Embedded systems, SpringerOpen, 2009*

Articles de conférences (1/2)

[IEEE SiPS 2022] N. Monnier, D. Guibert, C. Tasse, N. Gac, E. Raffin, O. Smirnov, B. Hugo, **Multi-core multi-node parallelization of the radio interferometric imaging pipeline DDFacet**, *IEEE Workshop on Signal Processing Systems (SiPS), Nov 2022, Rennes, France*

[IEEE ICIP 2022] N. Monnier, F. Orieux, N. Gac, D. Guibert, C. Tasse, E. Raffin, **Fast Sky to Sky Interpolation for Radio Interferometric Imaging**, *IEEE International Conference on Image Processing (ICIP), Oct 2022, Bordeaux, France*

[FPL 2021] D. Diakite, N. Gac, M. Martelli, **OpenCL FPGA Optimizatioon guided by memory accesses and roofline model analysis applied to tomography acceleration**, *31th International Conference on Field Programmable Logic and Applications (FPL), Aug 2021, Dresden, Germany*

[CT meeting 2020] D. Diakite, M. Martelli, N. Gac, **An OpenCL pipeline implementation on Intel FPGA for 3D backprojection**, *International Conference on Image Formation in X-Ray Computed Tomography, 2020, Regensburg*

[IEEE ICIP 2020] M. Seznec, N. Gac, F. Orieux, A. Sashala Naik, **An efficiency-driven approach for real-time optical flow processing on parallel hardware**, *IEEE International Conference on Image Processing (ICIP), 2020, Abu Dhabi*

[IEEE RTSCA 2020] M. Chghaf, N. Gac, **Data distribution on a multi-GPU node for TomoBayes CT reconstruction**, *IEEE Conference on Embedded and Real-Time Computing Systems and Applications (RTSCA), 2020, South Korea*

[Fully3D 2019] N. Georgin, C. Chapdelaine, N. Gac et al,**Multi-streaming and multi-GPU optimization for a matched pair of Projector and Backprojector** , *2019 Fully 3D, Jun 2019, Philadelphia, US*

[CT meeting 2018] C. Chapdelaine, N. Gac, A. Mohammad-Djafari, E. Parra,**New GPU implementation of Separable Footprint (SF) Projector and Backprojector : first results** , *International Meeting on Image Formation in X-Ray Computed Tomography, Salt Lake City, US, 2018*

[IEEE SiPS 2018] M. Seznec, N. Gac, A. Ferrari, F. Orieux, **A Study on Convolution Using Half–Precision Floating–Point Numbers on GPU for Radioastronomy Deconvolution** , *IEEE SIPS, Cape Town, South Africa, October 2018*

[Fully3D 2017] M. Dumitru, N. Gac ,L. Wang, A. Mohammad-Djafari, **Unsupervised sparsity enforcing iterative algorithms for 3D image reconstruction in X-ray Computed Tomography**, *Fully3D, 2017*

Articles de conférences (2/2)

[BEBEC 2014] N. Chu, N. Gac, J. Picheral, A. Mohammad-Djafari, **2D Convolution model using (in)variant kernels for fast acoustic imaging**, *BEBEC 2014, Berlin Beamforming Conference, 15 p., 2014*

[CT meeting 2014] L. Chen, T. Rodet, N. Gac, **A simple and efficient super-short-scan algorithm of fan-beam reconstruction for multiple circular trajectories : solution towards the truncated data**, *CT Meeting, Salt Lake City, pp. 212-215, 2014*

[IEEE NSS 2013] L. Chen, T. Rodet, N. Gac, **A penalized weighted least-squares image reconstruction based on scatter correction methods for X-ray CT**, *2013 IEEE NSS and MIC, Seoul, 2013*

[FVR 2011] N. Gac, A.Vabre, A. Mohammad-Djafari, **Multi GPU parallelization of 3D bayesian CT algorithm and its application on real foam reconstruction with incomplete data set**, *FVR, Poitiers, 2011*

Logiciels et brevet

[TomoGPI 2022] N. Gac, D. Diakiate, A. Djafari, **TomoGPI - logiciel de reconstruction en tomographie CT accéléré sur GPU/FPGA**

[TomoBayes 2019] C. Chapdelaine, N. Gac, T. Boulay, A. Djafari, E. Parra, Y. Le Guilloux, N. Georgin, **TomoBayes - logiciel de reconstruction en tomographie CT**, *v1.0 2015 v2.0 2019*

[TomoGPI 2018] M. Dumitru, L. Wang, N. Gac et A. Mohammad-Djafari, **Toolbox opensource Astra**, *Ref interne CNRS du pré-dépôt APP 1562-02, 2018*

[TomoGPI 2014] N. Gac et A.Mohammad-Djafari, **opgpuTomoGPI - parallélisastion multi-GPU**, *Ref interne CNRS du pré-dépôt APP 1562-01, 2014*

[Brevet SAFRAN 2019] C. Chapdelaine, A. Mohammad-Djafari, E. Parra, N. Gac, **Procédé et dispositif de contrôle non-destructif d'une pièce**, *France, Num de brevet : 18/53648. 2018*